

Лекция 1. Точный поиск паттерна в тексте

ГЛАВА I.

ТОЧНЫЙ ПОИСК ПАТТЕРНА В ТЕКСТЕ

* * *

I.1. Префикс-функция

Определение 1. (Супрефикс) Строка T называется *супрефиксом* строки S , если она является одновременно и префиксом, и суффиксом строки S .

Например, для строки «abacaba» супрефиксами являются строки «», «а», «аба» и сама «abacaba».

Примечание: пустая строка и сама строка S всегда являются её супрефиксами. Супрефикс, не равный всей строке, называется *собственным*.

Определение 2. (Префикс-функция) Префикс-функцией от строки S называют такой массив $\pi(S)$ длины $|S| + 1$, что $\pi(S)[i]$ равно длине максимального собственного (то есть не равного всей строке) супрефикса строки $S.substr(0, i)$, $0 \leq i \leq |S|$.

Примечание: $S.substr(0, i)$ — это префикс строки S длиной i символов. У пустого префикса собственных супрефиксов нет, поэтому полагаем $\pi[0] = 0$.

Алгоритм 1. (Алгоритм за линию)

Заведём одну переменную k — длину текущего супрефикса-кандидата. Она объявляется один раз перед перебором всех i (изначально $k = 0$, так как $\pi[0] = 0$). К моменту, когда мы хотим посчитать $\pi[i + 1]$, мы уже посчитали все $\forall j \leq i \pi[j]$, а в k уже лежит значение $\pi[i]$, оставшееся с предыдущего шага.

Отдельно: при $i = 0$ шаги ниже не нужны — $S[k]$ и $S[i]$ это один и тот же символ ($k = i = 0$), сравнивать нечего, и $\pi[1] = 0$ всегда (у односимвольной строки нет непустой собственной границы).

1. Смотрим на символ $S[k]$. Если он равен $S[i]$, тогда значение $\pi[i + 1]$ равно $k + 1$ (так как мы продолжили и предыдущий супрефикс, и соответствующий ему суффикс, а значит длина супрефикса увеличилась на 1, также он не может увеличиться больше, чем на 1, так как иначе, убрав последний символ, мы бы увеличили $\pi[i]$, а мы знаем, что он уже посчитан правильно, противоречие). Увеличиваем k на 1 и переходим к следующему i .
2. Если $S[k] \neq S[i]$, мы смотрим на более короткий супрефикс — тот, что продолжает границу текущего кандидата, а его длина как раз $\pi[k]$. То есть мы меняем $k = \pi[k]$ и рекурсивно продолжаем алгоритм на шаге 1 (для того же i).

3. Если мы в итоге смогли завершиться на шаге 1, переходим к следующему i . Иначе мы скатились в 0 (то есть $k = 0$) и тогда на шаге 1 сравниваем $S[0]$ с $S[i]$: если равны, k становится 1 (это и есть $\pi[i + 1]$), если нет — k остаётся 0 (это тоже $\pi[i + 1]$).

Время работы

На первый взгляд кажется, что раз на шаге 2 может быть много откатов подряд, то на одну позицию i алгоритм способен потратить много времени, значит суммарно выйдет не $O(n)$.

Но всего есть два вида событий, которые меняют k :

- Шаг 1 с совпадением — k увеличивается ровно на 1, и таких событий за весь алгоритм не больше n (по одному на каждый переход $i \rightarrow i + 1$).
- Шаг 2 (откат) — k каждый раз строго уменьшается (так как $\pi[k] < k$ при $k > 0$: супрефикс всегда короче самой строки, которую он продолжает).

Увеличений за весь алгоритм не больше n , значит и откатов (шагов 2) — тоже не больше n . Каждый откат — это $O(1)$ работы, значит на все откаты суммарно уходит $O(n)$. А на сам просмотр $S[k]$ для каждого i уходит ещё $O(n)$ — по $O(1)$ на каждый. Итого — $O(n)$ на весь алгоритм.

Реализация (C++)

```
void compute_prefix_function(const std::string& text, std::vector<int>& prefix)
{
    int length = text.size();
    prefix.assign(length + 1, 0); // prefix[0] = prefix[1] = 0 — у односимвольной
                                // строки не бывает непустой собственной
    границы
    int border = 0;
    for (int index = 1; index < length; ++index) {
        while (true) {
            if (text[border] == text[index]) { // шаг 1
                ++border;
                break;
            }
            if (border == 0) { // шаг 3
                break;
            }
            border = prefix[border]; // шаг 2
        }
        prefix[index + 1] = border;
    }
}
```

*

Алгоритм 2. (КМП (Кнут — Моррис — Пратт)) Задача: найти все вхождения образца t длины m в строку s длины n .

Решение: строим строку $u = t\#s$, где $\#$ — символ-разделитель, не встречающийся ни в t , ни в s . Считаём на u префикс-функцию.

Разделитель $\#$ необходим, чтобы чётко разделить строки t и s и в ходе подсчёта префикс-функции у нас супрефикс никогда не превысит m , так как на $m+1$ месте стоит символ, не встречающийся нигде, кроме этой позиции.

Из-за этого нам достаточно посмотреть на значение префикс-функции: на всех местах, где записано число m , будут заканчиваться вхождения строки t в строку s .

Пример: $t = \text{«aba»}$, $s = \text{«abacaba»}$. $u = \text{«aba\#abacaba»}$. Префикс-функция для этой строки — $[0, 0, 0, 1, 0, 1, 2, 3, 0, 1, 2, 3]$. Мы видим, что на позициях 7 и 11 стоят тройки, значит там заканчиваются вхождения строки t . Действительно: $abacaba$ содержит aba на позициях 0 и 4.

Время работы

Строка u имеет длину $n + m + 1$, а префикс-функция считается за линию от длины строки, поэтому весь поиск занимает $O(n + m)$.

Реализация (C++)

```
void find_occurrences(const std::string& pattern, const std::string& source,
                     std::vector<int>& occurrences) {
    std::string combined = pattern + '#' + source;
    std::vector<int> prefix;
    compute_prefix_function(combined, prefix);
    int pattern_length = static_cast<int>(pattern.size());
    for (std::size_t index = 0; index < prefix.size(); ++index) {
        if (prefix[index] == pattern_length) {
            occurrences.push_back(static_cast<int>(index) - 2 * pattern_length - 1);
        }
    }
}
```

*

1.2. Z-функция

Определение 3. (Z-function) Z-функцией от строки S называют такой массив $z(S)$ длины $|S|$, что $z(S)[i]$ равно длине максимального префикса строки $S[i:]$, который одновременно является и префиксом всей строки S .

Примечание: обычно считается, что Z-функция в нулевой позиции равна 0.

Определение 4. (Z-блок) Z-блоком назовём подстроку с началом в позиции i и длиной $z[i]$.

Алгоритм 3. (Линейный алгоритм)

Пусть переменная $left$ - это левая граница самого правого Z-блока (если таких несколько, самого большого), а $right$ - правая граница этого же Z-блока. Эти переменные будут обновляться по мере вычисления z-функции.

Пусть на текущем этапе мы хотим посчитать $z[i]$, и $\forall j < i$ мы уже посчитали $z[j]$. Тогда есть 2 варианта:

- 1 $i > right$: тогда пройдемся j от 0 и будем сравнивать $S[i + j]$ и $S[j]$, пока они совпадают. Как только не совпало, останавливаемся: в $z[i]$ кладем j (столько символов совпало в префиксах S и $S.substr(i)$), а границы обновляем на $left = i$, $right = i + j - 1$ (это последний из совпавших символов).
- 2 $i \leq right$: тогда мы знаем, что подстрока $S[left...right]$ совпадает с префиксом S . Значит ответ для i начинается также, как и для $i - left$ (так как i попадает в отрезок $[left, right]$, то есть $S[0] = S[left]$, ..., $S[right - left] = S[right]$).
 - 1 Если $i + z[i - left] \leq right$, то есть, если у нас ответ для $z[i - left]$ не выходит за границы уже посчитанного блока, тогда $z[i] = z[i - left]$ (все значения мы уже посчитали ранее)
 - 2 Если же $i + z[i - left] > right$, то вплоть до $right$ всё точно совпадает, так что просто продолжаем сравнивать $S[i + j]$ и $S[j]$ дальше, начиная с $j = right - i + 1$ (а не с нуля — иначе досчитывали бы уже известное заново). Получившееся значение — это $z[i]$, границы обновляем так же, как в первом пункте.

Время работы

На первый взгляд кажется, что раз в пункте 2.2 можно каждый раз досравнивать посимвольно, суммарно выйдет не $O(n)$. Но `right` за весь алгоритм только растёт и не может превысить $n - 1$, а каждое совпавшее сравнение (в пунктах 1 и 2.2) продвигает его на 1 — значит суммарно совпавших сравнений не больше n . А несовпавшее сравнение на каждой позиции i всего одно (сразу её останавливает). Итого — $O(n)$.

Реализация (C++)

```
void compute_z_function(const std::string& text, std::vector<int>& z_function) {
    int length = text.size();
    z_function.assign(length, 0);
    int left = 0, right = 0;
    for (int index = 1; index < length; ++index) {
        int j = 0;
        if (index <= right) { // шаг 2
            if (index + z_function[index - left] <= right) { // шаг 2.1
                z_function[index] = z_function[index - left];
                continue;
            }
            j = right - index + 1; // шаг 2.2
        }
        while (index + j < length && text[index + j] == text[j]) { // шаг 1 / хвост
шага 2.2
            ++j;
        }
        z_function[index] = j;
        left = index;
        right = index + j - 1;
    }
}
```

*

1.3. Полиномиальные хэши

Определение 5. (Полиномиальная хэш-функция)

Полиномиальная хэш-функция для строки S определяется как

$$h(S) = \left(\sum_{i=0}^{|S|-1} S[i] \cdot x^i \right) \bmod p$$

где p - простое, а $x \in \mathbb{Z}_p^*$

Заметим, что $h(Sc)$, где c - это символ, который мы добавляем к строке, равен $\left(\sum_{i=0}^{|S|-1} S[i] \cdot x^i \right) \bmod p + c \cdot x^{|S|} \bmod p = (h(S) + c \cdot x^{|S|}) \bmod p$

Функция для расчёта полиномиального хэша (C++)

```
long long polynomial_hash(const std::string& text, long long x, long long mod) {
    long long hash = 0;
    long long power = 1; //  $x^0 = 1$  — множитель для самого первого символа
    for (std::size_t index = 0; index < text.size(); ++index) {
        hash = (hash + text[index] * power) % mod;
        power = (power * x) % mod;
    }
    return hash;
}
```

*

Утверждение 1. (Хэш подстроки) Пусть $h[i] = h(S.substr(0, i + 1))$ и $h[-1] = 0$, тогда

$$h(S.substr(l, r - l)) = (h[r - 1] - h[l - 1]) \cdot (x^l)^{-1} \bmod p$$

Деление здесь — умножение на обратный к x^l по модулю p (он существует, так как p простое и $x \in \mathbb{Z}_p^*$).

Действительно, для того, чтобы посчитать хэш подстроки $S[l..r - 1]$, достаточно из хэша префикса, заканчивающегося в $r - 1$, вычесть хэш префикса, заканчивающегося в $l - 1$, и всё это поделить на x^l : каждый следующий $h[i]$ получается из $h[i - 1]$ добавлением слагаемого $S[i] \cdot x^i$ (см. примечание выше), поэтому $h[r - 1] = h[l - 1] + S[l] \cdot x^l + S[l + 1] \cdot x^{l+1} + \dots + S[r - 1] \cdot x^{r-1}$ — а это как раз хэш подстроки $S[l..r - 1]$, домноженный на x^l (сдвиг степеней из-за того, что подстрока начинается не с позиции 0).

Алгоритм 4. (Рабина-Карпа) Задача та же, что и в алгоритме КМП

1. Посчитаем хэш паттерна
2. Посчитаем хэши всех префиксов текста
3. Для каждой подстроки текста с длиной паттерна посчитаем её хэш вышеописанным способом и сравним с хэшем паттерна. Если хэши не совпали — подстрока точно не равна паттерну; если совпали — сравниваем посимвольно (хэши могут совпасть и у разных строк — коллизия).

Теорема 1. (б/д)

Если x выбирается случайно, то для двух различных строк длины $|P|$ вероятность коллизии полиномиальной хэш-функции не превосходит $\frac{|P|-1}{p}$ (разность хэшей — ненулевой многочлен степени не выше $|P| - 1$, у него не больше $|P| - 1$ корней).

Следствие 1. Выбрав простое $p > |P|^2$, получаем, что вероятность коллизии меньше $\frac{1}{|P|}$. Проверка каждой коллизии стоит $O(|P|)$, а значит, в среднем время работы составит

$$O\left(|P| + |T| \left(1 + |P| \cdot \frac{1}{|P|}\right)\right) = O(|P| + |T|)$$

Примечание автора: многие олпрогеры очень любят хэши за их простоту и быстроту написания и очень любят пытаться запихнуть их везде, где только можно. С первого взгляда это может показаться очень хорошей идеей: действительно, зачем учить множество строковых алгоритмов, если можно выучить одни хэши и с их помощью решать огромное количество задач с практически оптимальной асимптотикой. Однако у такого подхода есть один существенный минус: к любому хэшу можно подобрать контр-тест, на котором возникнет коллизия, и ваше решение перестанет работать. Да, вероятность того, что такое произойдёт очень мала, однако в реальной жизни именно из-за этого программисты предпочитают использовать пусть более сложные, но гораздо более надёжные и стабильные алгоритмы, нежели хэши. Поэтому призываю вас не пытаться всё решить хэшами, а разобраться с остальными алгоритмами и там, где их можно использовать, применять именно их.